

Construyendo un Ecosistema de Datos Local: Del Dato Crudo al Insight.

Implementando Spark 3.5, MinIO, PostgreSQL 15 y Delta Lake bajo la Arquitectura Medallion en Ubuntu 24.04.




El ecosistema de datos funciona exactamente como una cocina profesional de alta eficiencia.



La Regla de Oro: Los notebooks NO guardan datos; guardan código (las recetas).
Los datos viven exclusivamente en MinIO o PostgreSQL.

La separación estructural entre el lago de datos masivo y el almacén relacional.

MinIO (Almacenamiento de Objetos / S3)




Estructura: Buckets con millones de archivos (CSV, Parquet, Delta).

Escala: Petabytes de procesamiento masivo. Integración nativa S3A con Spark.

Limitación: Sin SQL nativo; no apto para JOINS complejos ni transacciones sin Delta.

Uso: Todo el Data Lake (Capas Bronze, Silver, Gold).

PostgreSQL 15 (Base de Datos Relacional)



Estructura: Tablas con schema fijo, claves primarias y foráneas.

Escala: GBs a TBs. Optimizado para transacciones ACID rápidas y reporting.

Limitación: No escala para archivos masivos (BLOBs) ni semi-estructurados profundos.

Uso: Solo tablas Gold para Dashboards, BI y consultas SQL.


Delta Lake no es un nuevo formato; es un escudo transaccional que envuelve y potencia a Parquet.



Fase 1

CSV (El caparazón externo)


Texto plano, universal y legible. Sin compresión ni tipos de datos. Lento para leer columnas específicas.



Fase 2

Parquet (El núcleo comprimido)

Binario columnar. Reduce el tamaño un ~70%. Splittable para Spark. Lectura ultra-rápida. Sin ACID.



Fase 3

Delta Lake (El escudo protector)

Capa de gestión sobre Parquet. Añade transacciones ACID, Time Travel, validación de schema y capacidades de MERGE/UPSERT.

Matriz de decisión técnica para el almacenamiento físico de los datos.

	CSV	Parquet	Delta Lake
Legible por humanos:	✓	✗	✗
Compresión y Tipos:	✗	✓	✓
Divisible (Splittable):	⚠ A veces	✓	✓
Transacciones ACID:	✗	✗	✓
Time Travel:	✗	✗	✓
MERGE / UPSERT:	✗	✗	✓

CSV

Ideal para intercambio humano o fuentes externas.



Parquet

Ideal para almacenamiento intermedio estático en Spark.




Delta

El estándar para tablas productivas y datos activos (Silver/Gold).



Incrementando la calidad del dato a través de tres zonas de refinamiento continuo.



Capa Bronze (Crudo)

Copia exacta e inmutable de la fuente. Respaldo total.


Capa Silver (Limpio)

Datos limpios, deduplicados y con schema fijo (Formato Delta).

Capa Gold (Modelado)

Modelos dimensionales listos para el consumo de BI y ML.

Capa Bronze: Preservando el historial inmutable para auditoría y reprocesamiento.



Inmutabilidad: Los datos llegan exactamente como salieron de la fuente. Nunca se modifican.

Seguridad y Backup: Si algo falla en los procesos posteriores, se puede reconstruir todo desde esta capa.

Protocolo de Acceso: Spark lee los datos desde MinIO utilizando el protocolo nativo s3a://.


El valor oculto de Bronze:

Los auditores siempre exigirán ver el dato original sin transformar. Esta capa es el seguro de vida del Data Engineer.

Capa Silver: El motor de limpieza donde el dato crudo se convierte en información confiable.



1. **Deduplicación:** Eliminación de registros repetidos.
2. **Gestión de Nulos:** Imputación o descarte de valores inexistentes.
3. **Casteo de Tipos:** Conversión estricta (ej. ``String`` → ``Date``).
4. **Normalización:** Estandarización de monedas, fechas y formatos.



La Ventaja Delta

Aquí ocurre la magia del ``MERGE`/`UPSERT``. En lugar de reescribir todo el archivo Parquet, Delta Lake permite actualizar registros existentes e insertar nuevos basados en el diario de transacciones JSON (``_delta_log/``).



Capa Gold: Estructurando modelos dimensionales diseñados para el consumo de negocio.




Propósito Específico: A diferencia de Silver, Gold no guarda todo. Guarda lo que el negocio necesita responder.

Estructuras Clásicas: Creación de tablas dimensionales (``dim_customer``, ``dim_product``) y tablas de hechos (``fact_sales``).


Agregaciones: KPIs pre-calculados (``monthly_customer_metrics``) para tiempos de respuesta sub-segundo.

Regla de Despliegue:

Las herramientas de Business Intelligence (PowerBI, Tableau) se conectan directamente a PostgreSQL mediante JDBC para consumir esta capa.




El panel de control: Orquestando el ciclo de vida mediante cuadernos Jupyter.



Insight Clave:

Separación estricta de responsabilidades. Cada notebook tiene una entrada definida, una transformación específica y una salida clara.

Escenario Real: El viaje completo de un archivo de transacciones financieras.



Origen

Archivo
transacciones_marzo.csv
llega de un sistema externo.



Ingesta → Bronze

PySpark guarda el CSV
idéntico en
s3a://bronze/raw_tx/.
(Backup asegurado).



Limpieza → Silver

Spark lee de Bronze, elimina
duplicados, convierte fechas,
y hace un MERGE en una
tabla Delta en
s3a://silver/transactions/.



Agregación → Gold

Spark agrupa las ventas por
sucursal y escribe la tabla
estructurada final en
PostgreSQL
(fact_monthly_sales).



Consumo

El equipo de BI consulta
PostgreSQL para el
dashboard de ingresos.

Principios fundamentales para mantener el ecosistema local.

Rule 1: Separar Cómputo de Almacenamiento.



Rule 2: Delta Lake es el Estándar de Calidad.



Rule 3: Inmutabilidad en el Origen.



Rule 4: Consumo Específico en Gold.

